

统计学笔记

Ruijun Shi¹

2021 年 11 月 18 日

¹GitHub : <https://github.com/RuijunShi>

摘要

简单的统计学笔记，主要是在天文学，特别是引力波和pulsar timing中遇到的统计学，现在没写多少内容。缓慢更新中[1]。同时这也是我第一次用latex编写书籍，学习过程艰难啊。有错误请大家指出！
latex资料参考<https://github.com/Ali-loner>

Contents

1	代数基础	3
2	数理统计基础	4
2.1	概率	4
2.2	单变量分布	5
2.3	常见分布	5
2.4	多元随机变量	6
2.5	随机变量的数学特征	6
2.6	频率学派的参数估计	6
2.7	频率学派的假设检验	6
3	贝叶斯统计	7
3.1	贝叶斯定理推导	7
3.2	贝叶斯单参数估计	7
3.3	贝叶斯多参数模型	11
3.4	Chapter 5层次化模型	13
3.5	贝叶斯回归	18
3.6	贝叶斯模型选择	18
4	随机过程	19
4.1	随机过程及其统计描述	19
4.2	平稳随机过程	19
4.3	马尔科夫链	19
5	MCMC	20
5.1	拒绝-接受采样	20
5.2	吉布斯采用	20
5.3	M-H采样	20
5.4	Nested采样	20
6	高斯随机过程	21

6.1	高斯随机过程及其统计描述	21
6.2	核密度估计	21
6.3	高斯混合模型	21
6.4	高斯学习	21

Chapter 1

代数基础

未完待续。。。 图片测试 SVD分解 1.1




图 1.1: tSVD分解

Chapter 2

数理统计基础

2.1 概率

1. 概率的定义（略）概率满足：非负性，规范性，可列可加性

2. 概率的性质：

重点：逆事件概率；加法公式；有限可加性

3. 条件概率：

$$P(A|B) = \frac{P(AB)}{P(B)} \quad (2.1)$$

4. 乘法定理：

$$P(AB) = P(A|B)P(B) \quad (2.2)$$

5. 全概率公式：

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n) \quad (2.3)$$

6. 独立性：满足

$$P(AB) = P(A)P(B) \quad (2.4a)$$

$$P(B|A) = P(B) \quad (2.4b)$$

$$(2.4c)$$

2.2 单变量分布

1. 随机变量的概念（略）

2. 分布函数的概念（略）和性质：不减函数； $0 \leq F(x) \leq 1$ ； $F(x+0) = F(x)$

3. 概率密度函数

$$F(x) = \int_{-\infty}^x f(t)dt \quad (2.5)$$

性质：

$$f(x) \geq 0 \quad (2.6a)$$

$$\int_{-\infty}^{\infty} f(x)dx = 1 \quad (2.6b)$$

$$P\{x_1 < X < x_2\} = \int_{x_1}^{x_2} f(x)dx \quad (2.6c)$$

$$F'(x) = f(x) \quad (2.6d)$$

2.3 常见分布

1. (0-1)分布:

$$P(X = k) = p^k(1-p)^{1-k}, 0 < p < 1, k = 0, 1 \quad (2.7)$$

2. 二项分布:

$$P(X = k) = \binom{n}{k} p^k(1-p)^{n-k} \quad (2.8)$$

3. 泊松分布:

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, k = 0, 1, 2, \dots \quad (2.9)$$

4. Beta分布:

$$f(x) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1}(1-x)^{\beta-1} \quad (2.10)$$

其中： $0 \leq x \leq 1$, $\alpha > 0$, $\beta > 0$, $\Gamma(z) = \int_0^{+\infty} t^{z-1} e^{-t} dt$

5. 均匀分布:

$$f(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{otherwise} \end{cases} \quad (2.11)$$

6. 指数分布:

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} & x > 0 \\ 0 & \text{otherwise} \end{cases} \quad (2.12)$$

7. 正态分布:

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (2.13)$$

$f(x)$ 关于 μ 对称; $f(\mu) = \max(f(x)) = \frac{1}{\sqrt{2\pi}\sigma}$ 。

8. *Gamma*分布:

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \quad (2.14)$$

其中: $x > 0, \alpha > 0, \beta > 0$

9. *Inv-Gamma*分布:

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{-(\alpha+1)} e^{-\frac{\beta}{x}} \quad (2.15)$$

其中: $x > 0, \alpha > 0, \beta > 0$

10. χ^2 分布:

$$f_k(x) = \frac{1}{2^{\frac{k}{2}} \Gamma(\frac{k}{2})} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} \quad (2.16)$$

等价 $\alpha = k/2, \beta = 1/2$ 的Gamma分布

11. *Inv- χ^2* 分布:

$$f(x) = \frac{2^{-\frac{k}{2}}}{\Gamma(\frac{k}{2})} x^{-(\frac{k}{2}+1)} e^{-\frac{1}{2x}} \quad (2.17)$$

等价 $\alpha = k/2, \beta = 1/2$ 的Inv-Gamma分布

12. Scaled *Inv- χ^2* 分布:

$$f(x) = \frac{\frac{k}{2} - \frac{k}{2} s^k}{\Gamma(\frac{k}{2})} x^{-(\frac{k}{2}+1)} e^{-\frac{ks^2}{2x}} \quad (2.18)$$

等价 $\alpha = k/2, \beta = ks^2/2$ 的Inv-Gamma分布。

2.4 多元随机变量

2.5 随机变量的数学特征

2.6 频率学派的参数估计

2.7 频率学派的假设检验

Chapter 3

贝叶斯统计

3.1 贝叶斯定理推导

1. 贝叶斯公式

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)} = \frac{P(A|B_i)P(B_i)}{P(A)} \quad (3.1)$$

先验: $P(B)$

似然: $P(A|B)$

后验: $P(B|A)$

证据 (归一化): $P(A)$

2. 贝叶斯公式含义: 通过数据推算模型参数的概率。即:

$$P(\text{Model}(\theta)|\text{Data}) = P(\text{Data}|\text{Model}(\theta))P(\theta) \quad (3.2)$$

3. 贝叶斯统计的优势: 将这个某种程度上是主观性的信息明确表达在先验概率中, 而不是隐藏在没有明确指出的假设中; 让数据说话, 减少主观性的先验概率。

3.2 贝叶斯单参数估计

一、二项分布估计

1. 无信息先验

- 似然:

$$p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y} \quad (3.3)$$

- 先验：均匀分布
- 后验：

$$p(\theta|y) \propto \theta^y (1-\theta)^{n-y} \sim \text{Beta}(y+1, n-y+1)$$

- 预测：

$$Pr(\tilde{y} = 1|y) = \int_0^1 Pr(\tilde{y} = 1|\theta, y) = \int_0^1 \theta p(\theta|y) d\theta = E(\theta|y)$$

1. 有信息先验

- 先验： $p(\theta) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1}$
- 似然：

$$p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y} \quad (3.4)$$

- 后验：

$$p(\theta|y) \propto \theta^{y+\alpha-1} (1-\theta)^{n-y+\beta-1} \sim \text{Beta}(\alpha+y, \beta+n-y)$$

- 后验期望： $E(\theta|y) = \frac{\alpha+y}{\alpha+\beta+n}$
- 先验期望： $E(y) = \frac{\alpha}{\alpha+\beta}$

当 $n \rightarrow \infty$: $E(\theta|y) \rightarrow y/n$

数据很大的时候可以用正态分布近似后验分布

二、正态分布参数估计

1. 已知方差求均值

- 似然：

$$p(y|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(y-\theta)^2\right] \sim N(\theta, \sigma^2)$$

- 先验：

$$p(\theta) \propto \exp\left(-\frac{1}{2\tau_0^2}(\theta - \mu_0)^2\right) \sim N(\mu_0, \tau_0^2)$$

- 后验:

$$p(\theta|y) \propto \exp\left(-\frac{1}{2\tau_1^2}(\theta - \mu_1)^2\right) \sim N(\mu_1, \tau_1)$$

其中:

$$\mu_1 = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{1}{\sigma^2}y}{\frac{1}{\tau_0^2} + \frac{1}{\sigma^2}}$$

$$\frac{1}{\tau_1^2} = \frac{1}{\tau_0^2} + \frac{1}{\sigma^2}$$

精度: 方差的倒数

- 预测:

$$\begin{aligned} p(\tilde{y}|y) &= \int p(\tilde{y}|\theta)p(\theta|y)d\theta \\ &\propto \int \exp\left(-\frac{(\tilde{y} - \theta)^2}{2\sigma^2}\right) \exp\left(-\frac{(\theta - \mu_1)^2}{2\tau_1^2}\right) d\theta \end{aligned}$$

$$E(\tilde{y}|\theta) = \theta$$

$$D(\tilde{y}|\theta) = \sigma^2 + \tau_1^2$$

- 多个相互独立数据:

$$\begin{aligned} p(\theta | y) &\propto p(\theta)p(y | \theta) \\ &= p(\theta) \prod_{i=1}^n p(y_i | \theta) \\ &\propto \exp\left(-\frac{1}{2\tau_0^2}(\theta - \mu_0)^2\right) \prod_{i=1}^n \exp\left(-\frac{1}{2\sigma^2}(y_i - \theta)^2\right) \\ &\propto \exp\left(-\frac{1}{2}\left[\frac{1}{\tau_0^2}(\theta - \mu_0)^2 + \frac{1}{\sigma^2}\sum_{i=1}^n (y_i - \theta)^2\right]\right) \end{aligned} \tag{3.5}$$

可得:

$$p(\theta|y_1, \dots, y_n) = p(\theta|\bar{y}) = N(\theta|\mu_n, \tau_n^2)$$

其中：

$$\mu_n = \frac{\frac{1}{\tau_0^2}\mu_0 + \frac{n}{\sigma^2}\bar{y}}{\frac{1}{\tau_0^2} + \frac{n}{\sigma^2}}$$

$$\frac{1}{\tau_n^2} = \frac{1}{\tau_0^2} + \frac{n}{\sigma^2}$$

若 $n \rightarrow +\infty$, τ_0 不变, 则: $\theta|y \sim N(\bar{y}, \sigma^2/n)$

若 $\tau \rightarrow +\infty$, n 不变, 则: $\theta|y \sim N(\bar{y}, \sigma^2/n)$

1. 已知均值求方差

由于有 n 个服从 $\sim N(\theta, \sigma^2)$ 的分布, 因此:

- 似然:

$$p(y|\sigma^2) \propto \sigma^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \theta)^2\right) = (\sigma^2)^{-n/2} e^{-\frac{n}{2\sigma^2} v}$$

其中:

$$v = \frac{1}{n} \sum_{i=1}^n (y_i - \theta)^2$$

- 共轭先验: $p(\sigma^2) \propto (\sigma^2)^{-\alpha+1} e^{\beta/\sigma^2} \sim \text{Inv} - \chi^2(v_0, \sigma_0^2)$
- 后验:

$$\begin{aligned} p(\sigma^2|y) &\propto p(\sigma^2)p(y|\sigma^2) \\ &\propto \left(\frac{\sigma_0^2}{\sigma^2}\right)^{v_0/2+1} \exp\left(-\frac{v_0\sigma_0^2}{2\sigma^2}\right) \cdot (\sigma^2)^{-n/2} \exp\left(-\frac{n}{2} \frac{v}{\sigma^2}\right) \\ &\propto (\sigma^2)^{-((n+v_0)/2+1)} \exp\left(-\frac{1}{2\sigma^2}(v_0\sigma_0^2 + nv)\right) \\ &\sim \text{Inv} - \chi^2(v_0 + n, \frac{v_0\sigma_0^2 + nv}{v_0 + n}) \end{aligned} \tag{3.6}$$

3.3 贝叶斯多参数模型

一、多参数模型处理

1. 置之不理

2. 边缘化

$$p(\theta_1|y) = \int p(\theta_1, \theta_2|y) d\theta_2 \quad (3.7)$$

用贝叶斯公式展开：

$$p(\theta_1, \theta_2|y) \propto p(y|\theta_1, \theta_2)p(\theta_1, \theta_2)$$

将 θ_2 边缘化积分，得到 θ_1 的后验分布。

3. 平均化

$$p(\theta_1|y) = \int p(\theta_1|\theta_2, y)p(\theta_2|y) d\theta_2$$

二、无信息先验的正态分布

- 先验：

$$p(\mu, \ln \sigma^2) \sim U(\mu, \ln \sigma^2)$$

或者先验写为：

$$p(\mu, \sigma^2) \sim \frac{1}{\sigma^2}$$

- 似然（有 n 次观测）：

$$p(y|\mu, \sigma^2) = \sigma^{-n} \exp \left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 \right)$$

- 联合后验：

$$p(\mu, \sigma^2|y) \propto \sigma^{-n-2} \exp \left(-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2] \right)$$

其中：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

- 边缘后验 $p(\sigma^2|y)$:

$$\begin{aligned} p(\sigma^2|y) &\propto \int p(\mu, \sigma^2|y) d\mu \\ &\propto (\sigma^2)^{-\frac{n+1}{2}} \exp\left(-\frac{(n-1)s^2}{2\sigma^2}\right) \\ &\sim \text{Inv} - \chi^2(n-1, s^2) \end{aligned}$$

- 边缘后验 $p(\mu|y)$:

$$\begin{aligned} p(\mu|y) &= \int_0^\infty p(\mu, \sigma^2|y) d\sigma^2 \\ &\propto \left[1 + \frac{n(\mu - \bar{y})^2}{(n-1)s^2} \right]^{-n/2} \\ &\sim t_{n-1}(\bar{y}, s^2/n) \end{aligned}$$

- 预测后验分布

$$p(\tilde{y}|y) = \iint p(\tilde{y}|\mu, \sigma^2, y) p(\mu, \sigma^2|y) d\mu d\sigma^2$$

三、共轭先验分布

- 先验分布:

$$\mu|\sigma^2 \sim N(\mu_0, \sigma^2/\kappa_0)$$

$$\sigma^2 \sim \text{Inv} - \chi^2(\nu_0, \sigma_0^2)$$

- 联合先验分布

$$\begin{aligned} p(\mu, \sigma^2) &= p(\mu|\sigma^2)p(\sigma^2) \\ &\propto N - \text{Inv} - \chi^2(\mu_0, \sigma_0^2/\kappa_0; \nu_0, \sigma_0^2) \end{aligned}$$

- 似然分布

$$p(y|\mu, \sigma^2) = \sigma^{-n} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2\right)$$

- 联合后验分布

$$\begin{aligned} p(\mu, \sigma^2 | y) &\propto \sigma^{-1} (\sigma^2)^{(\nu_0/2+1)} e^{-\frac{1}{2\sigma^2} [\nu_0 \sigma_0^2 + \kappa_0 (\mu - \mu_0)^2]} (\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} [(n-1)s^2 + n(\bar{y} - \mu)^2]} \\ &\propto \text{N-Inv-}\chi^2(\mu_n, \sigma_n^2/\kappa_n; \nu_n, \sigma_n^2) \end{aligned} \quad (3.8)$$

其中参数为：

$$\begin{aligned} \mu_n &= \frac{\kappa_0}{\kappa_0+n} \mu_0 + \frac{n}{\kappa_0+n} \bar{y} \\ \kappa_n &= \kappa_0 + n \\ \nu_n &= \nu_0 + n \\ \nu_n \sigma_n^2 &= \nu_0 \sigma_0^2 + (n-1)s^2 + \frac{\kappa_0 n}{\kappa_0+n} (\bar{y} - \mu_0)^2 \end{aligned} \quad (3.9)$$

- 条件后验分布 $p(\mu|\sigma^2, y)$

$$(\mu | \sigma^2, y) \sim \text{N}\left(\mu_n \frac{\sigma^2}{\kappa_n}\right)$$

- 方差边缘后验分布 $p(\sigma^2|y)$

$$(\sigma^2 | y) \sim \text{Inv-}\chi^2(\nu_n, \sigma_n^2)$$

- 均值边缘后验分布 $p(\mu|y)$

$$\begin{aligned} p(\mu | y) &\propto \left[1 + \frac{\kappa_n (\mu - \mu_n)^2}{\nu_n \sigma_n^2}\right]^{-(\nu_n+1)/2} \\ &= t_{\nu_n}(\mu | \mu_n, \sigma_n^2/\kappa_n) \end{aligned} \quad (3.10)$$

3.4 Chapter 5 层次化模型

一、参数化先验分布

1. 先验分布

先验分布是由某个未知参数的分布 ϕ 给出：

$$p(\theta|\phi) = \prod_{j=1}^J p(\theta_j|\phi) \quad \theta = (\theta_1, \theta_2, \dots)$$

边缘化：

$$p(\theta) = \int \left(\prod_{j=1}^J p(\theta_j | \phi) \right) p(\phi) d\phi$$

2. 联合先验分布 $p(\phi, \theta) = p(\theta | \phi)p(\phi)$

3. 超先验分布： $p(\phi)$

4. 后验分布

- 联合后验： $p(\phi, \theta | y) = p(y | \theta)p(\theta | \phi)p(\phi)$
- 条件后验： $p(\theta | \phi, y)$
- 边缘后验： $p(\phi | y)$

$$p(\phi | y) = \frac{p(\theta, \phi | y)}{p(\theta | \phi, y)}$$

5. 层次化贝叶斯完整表述

$$\begin{aligned} p(\phi, \theta | y) &\propto p(y | \phi, \theta)p(\phi, \theta) \\ &= p(y | \theta)p(\phi, \theta) \\ &= p(y | \theta)p(\theta | \phi)p(\phi) \end{aligned} \tag{3.11}$$

1. 层次化贝叶斯计算步骤

- 写出联合后验分布 $p(\theta, \phi | y)$ ：即超先验分布，总体分布和似然分布的乘积
- 确定条件后验分布 $p(\theta | \phi, y)$ ：

$$p(\theta | \phi, y) = \prod_{j=1}^J p(\theta_j | \phi, y)$$

- 边缘化给出 ϕ 的贝叶斯估计

二、二项分布的分层贝叶斯模型

1. y_i 先验（组内模型） $y_j \sim \text{Bin}(n_j, \theta_j)$
2. θ_j 先验（组间模型）： $\theta_j \sim \text{Beta}(\alpha, \beta)$
3. 联合先验： $p(\alpha, \beta, \theta) = p(\alpha, \beta)p(\theta | \alpha, \beta)$

4. 似然: $p(y|\theta, \alpha, \beta)$

5. 联合后验: $p(\theta, \alpha, \beta|y)$

$$\begin{aligned} p(\theta, \alpha, \beta|y) &\propto p(\alpha, \beta)p(\theta|\alpha, \beta)p(y|\theta, \alpha, \beta) \\ &= p(\alpha, \beta) \prod_{j=1}^J \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta_j^{\alpha-1} (1 - \theta_j)^{\beta-1} \prod_{j=1}^J \theta_j^{y_j} (1 - \theta_j)^{n_j - y_j} \end{aligned} \quad (3.12)$$

6. 条件后验: $p(\theta|\alpha, \beta, y)$: 单参数模型给定的后验

$$\begin{aligned} p(\theta | \alpha, \beta, y) &= \prod_{j=1}^J \frac{\Gamma(\alpha + \beta + n_j)}{\Gamma(\alpha + y_j) \Gamma(\beta + n_j - y_j)} \theta_j^{\alpha + y_j - 1} (1 - \theta_j)^{\beta + n_j - y_j - 1} \\ &\sim \prod_{j=1}^J \text{Beta}(\alpha + y_j, \beta + n_j - y_j) \end{aligned} \quad (3.13)$$

7. 边缘后验: $p(\alpha, \beta|y)$

$$\begin{aligned} p(\alpha, \beta | y) &= \frac{p(\theta, \alpha, \beta | y)}{p(\theta | \alpha, \beta, y)} \\ &\propto \frac{p(\alpha, \beta) \prod_{j=1}^J \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta_j^{\alpha-1} (1 - \theta_j)^{\beta-1} \prod_{j=1}^J \theta_j^{y_j} (1 - \theta_j)^{n_j - y_j}}{\prod_{j=1}^J \frac{\Gamma(\alpha + \beta + n_j)}{\Gamma(\alpha + y_j) \Gamma(\beta + n_j - y_j)} \theta_j^{\alpha + y_j - 1} (1 - \theta_j)^{\beta + n_j - y_j - 1}} \\ &= p(\alpha, \beta) \prod_{j=1}^J \frac{\Gamma(\alpha + \beta) \Gamma(\alpha + y_j) \Gamma(\beta + n_j - y_j)}{\Gamma(\alpha) \Gamma(\beta) \Gamma(\alpha + \beta + n_j)} \end{aligned} \quad (3.14)$$

三、正态分布的分层贝叶斯模型

1. 数据结构

假设 J 个独立试验, 每个实验都由 θ_j 给出其参数估计, 估计 n_j 个*i.i.d*正态分布的数据点 y_{ij} , 每个点方差为 σ^2 :

$$y_{ij}|\theta_j \sim N(\theta_j, \sigma^2) \quad i = 1, \dots, n_j \quad j = 1, \dots, J$$

样本均值 (充分统计量):

$$\bar{y}_{\cdot j} = \frac{1}{n_j} \sum_{i=1}^{n_j} y_{ij}$$

样本均值的分布

$$\bar{y}_{\cdot j} \sim N(\theta_j, \sigma_j^2)$$

样本方差:

$$\sigma_j^2 = \frac{\sigma^2}{n_j}$$

样本的均值是从 θ 中估计，样本方差是从 σ 中估计。

相当于 θ 的似然分布:

$$\bar{y}_{\cdot j} | \theta \sim N(\theta_j, \sigma_j^2)$$

由于 σ 是已知的，下面所有的分布都是在 σ 已知情况下成立。

1. 层次化模型：无信息先验

θ 是从参数 (μ, τ) 中抽取:

$$p(\theta_1, \dots, \theta_J | \mu, \tau^2) = \prod_{j=1}^J p(\theta_j | \mu, \tau^2)$$

边缘化:

$$p(\theta_1, \dots, \theta_J) = \iint \prod_{j=1}^J [p(\theta_j | \mu, \tau^2)] p(\mu, \tau^2) d\mu d\tau$$

• 先验和似然

组内抽样: $\bar{y}_{\cdot j} \sim N(\theta_j, \sigma_j^2)$

θ 的先验 (组内模型): $\theta | \mu, \tau \sim N(\mu, \tau^2)$

μ 的先验: $p(\mu, \tau) = p(\mu | \tau) p(\tau) \propto p(\tau)$

θ_j 似然分布: $p(y | \theta) \sim (\bar{y}_{\cdot j} | \theta) \sim N(\theta_j, \sigma_j^2)$

• 联合后验: $p(\theta, \phi | y)$

$$\begin{aligned} p(\theta, \mu, \tau | y) &\propto p(\mu, \tau) p(\theta | \mu, \tau) p(y | \theta) \\ &\propto p(\mu, \tau) \prod_{j=1}^J p(\theta_j | \mu, \tau^2) \prod_{j=1}^J p(\bar{y}_{\cdot j} | \theta_j, \sigma_j^2) \end{aligned} \quad (3.15)$$

其中： $\bar{y}_{\cdot j} \sim N(\theta_j, \sigma_j^2)$

可以忽略只依赖 y 和 σ_j 的参数，因为其已知。

- **θ 条件后验：** $p(\theta_j \mid \mu, \tau, y_{\cdot j})$

$$\theta_j \mid \mu, \tau, y_{\cdot j} \sim N(\hat{\theta}_j, V_j)$$

其中：

$$\hat{\theta}_j = \frac{\frac{1}{\sigma_j^2} \bar{y}_{\cdot j} + \frac{1}{\tau^2} \mu}{\frac{1}{\sigma_j^2} + \frac{1}{\tau^2}}$$

$$V_j = \frac{1}{\frac{1}{\sigma_j^2} + \frac{1}{\tau^2}}$$

- **超参数边缘后验：** $p(\mu, \tau \mid y)$

$$p(\mu, \tau \mid y) \propto p(\mu, \tau) p(y \mid \mu, \tau)$$

对于正态分布：

$$\bar{y}_{\cdot j} \sim N(\mu, \tau^2 + \sigma_j^2)$$

因此：

$$p(\mu, \tau \mid y) \propto p(\mu, \tau) \prod_{j=1}^J p(\bar{y}_{\cdot j} \mid \mu, \tau^2 + \sigma_j^2)$$

$$\bar{y}_{\cdot j} \mid \mu, (\tau^2 + \sigma_j^2) \sim N(\mu, \tau^2 + \sigma_j^2)$$

- **给定 τ 下 μ 的边缘后验分布：** $p(\mu \mid \tau, y)$ 从单参数模型中得出的结论

$$\mu \mid \tau, y \sim N(\hat{\mu}, V_\mu) \tag{3.16}$$

$$\hat{\mu} = \frac{\sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau^2} \bar{y}_{\cdot j}}{\sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau^2}}$$

$$V_{\mu}^{-1} = \sum_{j=1}^J \frac{1}{\sigma_j^2 + \tau^2}$$

- τ 的后验: $p(\tau | y)$

$$\begin{aligned} p(\tau | y) &= \frac{p(\mu, \tau | y)}{p(\mu | \tau, y)} \\ &\propto \frac{p(\tau) \prod_{j=1}^J N(\bar{y}_{\cdot j} | \mu, \sigma_j^2 + \tau^2)}{N(\mu | \hat{\mu}, V_{\mu})} \\ &\propto p(\tau) V_{\mu}^{1/2} \prod_{j=1}^J (\sigma_j^2 + \tau^2)^{-1/2} \exp\left(-\frac{(\bar{y}_{\cdot j} - \hat{\mu})^2}{2(\sigma_j^2 + \tau^2)}\right) \end{aligned} \quad (3.17)$$

- 从后往前采样，即先算出 τ 的后验，然后依次采样算出 μ 的后验，超参数联合后验， θ 的条件后验，联合后验等。

3.5 贝叶斯回归

3.6 贝叶斯模型选择

Chapter 4

随机过程

4.1 随机过程及其统计描述

4.2 平稳随机过程

4.3 马尔科夫链

Chapter 5

MCMC

5.1 拒绝-接受采样

5.2 吉布斯采用

5.3 M-H采样

5.4 Nested采样

Chapter 6

高斯随机过程

6.1 高斯随机过程及其统计描述

6.2 核密度估计

6.3 高斯混合模型

6.4 高斯学习

参考文献

- [1] JARANOWSKI, P., AND KRÓLAK, A. *Analysis of gravitational-wave data*. No. 29 in Cambridge monographs on particle physics, nuclear physics and cosmology. Cambridge University Press, Cambridge ; New York, 2009.